KARADENİZ TEKNİK ÜNİVERSİTESİ OF TEKNOLOJİ FAKÜLTESİ YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ

DERİN ÖĞRENME DERSİ

ÖDEV 1 RAPORU

FUNDA KUYBEN – 427612

GİTHUB LİNK : https://github.com/funda-kuyben/KTU-Derin-Ogrenme-Odevleri.git

2025 – 2026 BAHAR DÖNEMİ

1. PROBLEMİN TANIMI

Bu çalışmada meme kanseri tanısında kullanılan hücresel ölçüm özelliklerinden yararlanılarak tümörlerin iyi huylu (benign) veya kötü huylu (malignant) olarak sınıflandırılması amaçlanmıştır. Problem denetimli öğrenme kapsamında iki sınıflı (binary classification) bir makine öğrenmesi problemidir.

Veri seti Breast Cancer Wisconsin veri setidir ve toplam 30 sayısal öznitelik ile 1 sınıf etiketinden oluşmaktadır. Amaç, bu özellikleri kullanarak bir tümör örneğinin malignant (1) ya da benign (0) olduğunu tahmin eden bir model geliştirmektir.

Bu çalışmada malignant sınıf pozitif sınıf olarak kabul edilmiştir.

2. VERİ ÖN İŞLEME VE İŞLEM ADIMLARI

Model eğitilmeden önce veri setine aşağıdaki ön işleme adımları uygulanmıştır:

1. data.csv dosyası okunmuştur.
2. Kimlik bilgisi içeren id sütunu veri setinden çıkarılmıştır.
3. diagnosis sütunu sayısal hale dönüştürülmüştür (M = 1, B = 0).
4. Özellik matrisi (X) ve hedef değişken (y) ayrılmıştır.
5. Veri seti %80 eğitim ve %20 test olacak şekilde bölünmüştür.
6. Sınıf dağılımının korunması için stratify parametresi kullanılmıştır.
7. Özellikler farklı ölçeklerde olduğundan StandardScaler ile standardizasyon uygulanmıştır.

Ölçeklendirme yalnızca eğitim verisi üzerinde öğrenilmiş ve test verisine aynı parametrelerle uygulanmıştır. Böylece veri sızıntısı (data leakage) önlenmiştir.

3. SEÇİLEN ALGORİTMA VE SEÇİM GEREKÇESİ

Bu çalışmada sınıflandırma algoritması olarak Logistic Regression kullanılmıştır.

Logistic Regression'in tercih edilme nedenleri:

- İkili sınıflandırma problemlerine doğrudan uygun olması
- Hesaplama açısından verimli olması
- Parametre sayısının sınırlı olması
- Yorumlanabilir bir model olması
- Küçük ve orta ölçekli veri setlerinde başarılı sonuç vermesi

Model, özelliklerin doğrusal kombinasyonunu sigmoid fonksiyonu ile 0–1 aralığında bir olasılığa dönüştürür. Elde edilen olasılık belirli bir eşik değerine göre sınıfa dönüştürülür.

Bu problemde temel amaç malignant vakaları doğru şekilde tespit etmek olduğu için pozitif sınıf malignant olarak belirlenmiştir.

4. DEĞERLENDİRME METRİKLERİ

Model performansı aşağıdaki metriklerle değerlendirilmiştir:

- Accuracy
- Precision
- Recall (Sensitivity)
- F1-Score
- Confusion Matrix

Kullanılan metriklerin formülleri:

Accuracy = (TP + TN) / (TP + TN + FP + FN)
Precision = TP / (TP + FP)
Recall = TP / (TP + FN)
F1-Score = 2 · (Precision · Recall) / (Precision + Recall)

Sağlık alanına ait problemlerde özellikle Recall ve False Negative (FN) hataları büyük önem taşımaktadır. Çünkü FN durumunda hasta bir birey sağlıklı olarak tahmin edilir.

5. ELDE EDİLEN SONUÇLAR

Test verisi üzerinde elde edilen sonuçlar:

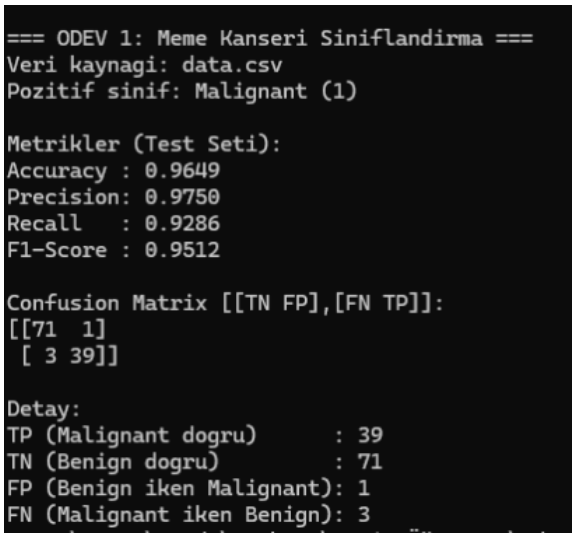

```
=== ODEV 1: Meme Kanseri Siniflandirma ===
Veri kaynagi: data.csv
Pozitif sinif: Malignant (1)

Metrikler (Test Seti):
Accuracy : 0.9649
Precision: 0.9750
Recall   : 0.9286
F1-Score : 0.9512

Confusion Matrix [[TN FP],[FN TP]]:
[[71  1]
 [ 3 39]]

Detay:
TP (Malignant dogru)      : 39
TN (Benign dogru)         : 71
FP (Benign iken Malignant): 1
FN (Malignant iken Benign): 3
```

Şekil 1. Modelin test verisi üzerindeki terminal çıktısı

Accuracy: 0.9649
Precision: 0.9750
Recall: 0.9286
F1-Score: 0.9512

Confusion Matrix sonuçları:

TP = 39
TN = 71
FP = 1
FN = 3

Toplam 114 test örneğinin 110'u doğru sınıflandırılmıştır. Bu sonuç, modelin test kümesinde %96.49 doğruluk sağladığını göstermektedir.

6. SONUÇLARIN DEĞERLENDİRİLMESİ

Model %96.49 doğruluk oranı elde etmiştir. Precision değerinin %97.50 olması, malignant tahminlerinin büyük ölçüde doğru olduğunu göstermektedir.

Recall değerinin %92.86 olması, gerçek malignant vakaların büyük çoğunluğunun doğru şekilde yakalandığını göstermektedir. Test kümesindeki 42 malignant vakanın 39'u doğru sınıflandırılmıştır.

FN sayısının 3 olması, modelin üç malignant vakayı benign olarak tahmin ettiğini göstermektedir. Sağlık uygulamalarında bu hata türü kritik olduğundan recall metriği özellikle önemlidir.

FP sayısı 1'dir. Bu durum sağlıklı bir bireyin yanlışlıkla hasta olarak sınıflandırılması anlamına gelir. FP hataları ek test ve maliyet oluşturabilir ancak FN kadar hayati risk taşımaz.

F1-Score değerinin yüksek olması, precision ve recall arasında dengeli bir performans olduğunu göstermektedir.

7. GENEL DEĞERLENDİRME

Bu çalışmada Logistic Regression yöntemi kullanılarak meme kanseri sınıflandırma problemi başarıyla çözülmüştür. Model, özellikle malignant vakaları yüksek oranda tespit edebilmiş ve klinik açıdan kritik olan yanlış negatif hata sayısını düşük seviyede tutmuştur. Elde edilen sonuçlar, seçilen yöntemin bu veri seti için uygun ve etkili olduğunu göstermektedir.